

Semana 11 - Sesión 2 (Sesión 22)

Ejercitación de pandas

Unidad V: práctica de manejo y análisis de datos

Coordinadora: C Loyola

Profesores C Femenías / C Ruiz / D García / S villanova

Primer Semestre 2026

Universidad Andrés Bello

Departamento de Física y Astronomía



Resumen - Semana 11, Sesión 2 (Sesión 22)

Introducción

Catálogo de estrellas

CSV real de exoplanetas

Cierre

Introducción

- Esta P2 es una sesión de ejercitación basada en la P1.
- Se reciclan ejercicios de Semana 8, pero reorganizados para reforzar la introducción a pandas.
- El foco es practicar un flujo completo de análisis: crear o leer datos, inspeccionar, filtrar, limpiar, agrupar y graficar.

Meta práctica

Que cada grupo termine con un DataFrame limpio, un resumen por categoría, un gráfico y un archivo CSV exportado.

- `pd.DataFrame`
- `pd.read_csv`
- `head`, `tail`, `shape`, `columns`, `info`, `describe`
- selección de columnas
- filtros con máscaras booleanas
- `isnull`, `dropna`, `fillna`
- creación de columnas derivadas
- `groupby`, `agg`, `value_counts`
- gráficos rápidos con `pandas` y `Matplotlib`
- `to_csv`

- Trabajar en parejas o grupos pequeños.
- Resolver primero sin mirar las soluciones.
- Probar el código por bloques: lectura, inspección, limpieza, análisis, gráfico.
- Comparar resultados con otro grupo antes de pasar al siguiente ejercicio.

Regla de trabajo

Antes de calcular o graficar, siempre inspeccionar el DataFrame.

Catálogo de estrellas

Catálogo de estrellas

Dataset base: catálogo simple de estrellas

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4
5 df = pd.DataFrame({
6     "estrella": ["Sol", "Alpha Cen A", "Proxima Cen", "Sirius A",
7                 "Tau Ceti", "Vega", "Barnard", "61 Cyg A",
8                 "Altair", "Epsilon Eri"],
9     "temperatura_K": [5778, 5790, 3042, 9940, 5344, 9602,
10                     3134, 4450, 7550, 5084],
11     "radio_Rsol": [1.00, 1.22, 0.15, 1.71, 0.79, 2.36,
12                  0.20, 0.67, 1.63, 0.74],
13     "distancia_pc": [0.00, 1.34, 1.30, 2.64, 3.65, 7.68,
14                    1.83, 3.48, 5.13, 3.22],
15     "magnitud_V": [-26.7, 0.01, 11.13, -1.46, 3.50,
16                  0.03, 9.54, np.nan, 0.77, 3.73],
17     "categoria": ["Solar", "Solar", "Enana roja", "Caliente",
18                  "Solar", "Caliente", "Enana roja",
19                  "Enana naranja", "Caliente", "Enana naranja"]
20 })
```




Enunciado

- Muestre las primeras y últimas filas con `head()` y `tail()`.
- Muestre los nombres de columnas con `df.columns`.
- Reporte qué representa cada columna numérica y sus unidades.

Conceptos: inspección inicial, lectura de columnas y unidades.



Enunciado

- Use `df.shape` para obtener dimensiones.
- Use `df.info()` para revisar tipos y valores no nulos.
- Use `df.describe()` para obtener estadísticas rápidas.
- Separe columnas numéricas y no numéricas usando `select_dtypes`.

Conceptos: estructura del DataFrame y diagnóstico inicial.



Enunciado

- Cree un subconjunto con `estrella`, `temperatura_K`, `distancia_pc` y `categoria`.
- Muestre las primeras filas del subconjunto.
- Explique por qué conviene reducir columnas antes de analizar.

Conceptos: selección de columnas y DataFrames derivados.



Enunciado

- Filtre estrellas con `temperatura_K > 5500`.
- Filtre estrellas con `distancia_pc < 4`.
- Combine ambas condiciones y muestre `estrella`, `temperatura_K`, `distancia_pc`.
- Cuente cuántas estrellas cumplen la condición combinada.

Conceptos: máscaras booleanas, `&`, conteo con `len()`.



Enunciado

- Cree una columna `luminosidad_rel` usando:

$$L_{\text{rel}} = R^2 \left(\frac{T}{5778} \right)^4$$

- Muestre `estrella`, `categoria` y `luminosidad_rel`.
- Ordene la tabla por luminosidad relativa de mayor a menor.

Conceptos: columnas derivadas y `sort_values`.



Enunciado

- Detecte valores faltantes con `df.isnull().sum()`.
- Cree `df_clean` eliminando filas con faltantes en `magnitud_V`.
- Cree `df_filled` rellenando `magnitud_V` con su promedio.
- Compare cuántas filas hay en cada DataFrame.

Conceptos: `dropna`, `fillna`, copias limpias.



Enunciado

- Agrupe por `categoría`.
- Calcule media de `temperatura_K`, `distancia_pc` y `luminosidad_rel`.
- Calcule también cuántas estrellas hay en cada categoría.

Conceptos: `groupby`, `agg`, conteos por grupo.



Enunciado

- Dibuje un histograma de `temperatura_K`.
- Dibuje un scatter de `distancia_pc` versus `magnitud_V`.
- Use título, nombres de ejes y grilla.

Conceptos: pandas plot, Matplotlib, gráficos exploratorios.



Enunciado

- Exporte `df_filled` como `catalogo_estrellas_limpio.csv`.
- Exporte el resumen por categoría como `resumen_estrellas.csv`.
- Use `index=False` cuando no quiera guardar el índice.

Conceptos: persistencia de resultados con `to_csv`.

CSV real de exoplanetas



Enunciado

- Lea el dataset `planets.csv` desde la URL de Seaborn.
- Muestre `head`, `shape`, `columns` e `info`.
- Identifique columnas numéricas y columnas categóricas.

Conceptos: `pd.read_csv`, inspección de datos reales.



Enunciado

- Seleccione las columnas `method`, `orbital_period`, `mass`, `distance`, `year`.
- Elimine filas con valores faltantes en esas columnas.
- Compare el número de filas antes y después.

Conceptos: selección, `dropna(subset=...)`.



Enunciado

- Filtre planetas detectados por `Radial Velocity`.
- Dentro de ese grupo, conserve planetas con `mass > 1` y `distance < 100`.
- Muestre `method`, `mass`, `distance`, `orbital_period`.

Conceptos: filtros múltiples y selección con `loc`.



Enunciado

- Agrupe `planets_clean` por método de detección.
- Calcule cantidad de planetas, distancia promedio, masa promedio y mediana del periodo orbital.
- Ordene por cantidad de planetas de mayor a menor.

Conceptos: `groupby`, `agg`, `sort_values`.



Enunciado

- Haga un histograma de **distance**.
- Haga un scatter de **orbital_period** versus **mass**.
- Use los datos limpios.
- Agregue título, etiquetas y grilla.

Conceptos: visualización exploratoria con datos reales.

Cierre

- ¿Qué comando fue más útil para entender la estructura del DataFrame?
- ¿Qué diferencia práctica hubo entre **dropna** y **fillna**?
- ¿Qué información entrega **groupby** que no se ve mirando fila por fila?
- ¿Qué gráfico fue más informativo para el dataset real?

- Usar `and` en vez de `&` para combinar filtros.
- Olvidar paréntesis alrededor de cada condición.
- Escribir `df[columna]` en vez de `df["columna"]`.
- Calcular estadísticas sin revisar nulos.
- Modificar el DataFrame original cuando convenía crear una copia.
- Exportar con índice cuando no era necesario.

- Practicamos un flujo completo de análisis de datos con pandas.
- Trabajamos con un DataFrame pequeño y con un CSV real.
- Aplicamos inspección, selección, filtrado, limpieza, agrupación, gráficos y exportación.
- Este flujo será la base para análisis estadístico con pandas, NumPy y Matplotlib.